DOI: 10.26618

Equilibrium: Jurnal Pendidikan Vol. XIV. Issu 1. Januari-April 2026

Perbandingan Agen LLM *Open-Weight* untuk Penilaian Otomatis Indikator Kurikulum Akreditasi LAM Teknik

[Nama Penulis][1], [Nama Pembimbing][2]

[1] Program Studi [...], [Institusi/Universitas] E-mail: [author@email.ac.id] [2] Program Studi [...], [Institusi/Universitas] E-mail: [author@email.ac.id]

Submitted: ..... ; Accepted: ..... ; Published: .....

ABSTRACT (IN ENGLISH)

Internal Quality Audit (Audit Mutu Internal, AMI) of higher education in Indonesia requires manual scoring of dozens of indicators against a complex rubric using two heterogeneous evidence sources: a qualitative Self-Evaluation Report (LED) and a quantitative Performance Report (LKPS). This study examines whether open-weight Large Language Model (LLM) agents can automate cross-modal scoring on seven core process-and-curriculum indicators, and how the agent paradigm — native function calling versus prompt-based JSON dispatch — affects performance. We implement a Retrieval-Augmented Generation (RAG) agent that cross-references vector-indexed LED chunks with structured LKPS tables through four specialized tools, and benchmark three open-weight models of comparable size (24–35 B parameters): qwen3.5:35b, deepseek-r1:32b, and mistral-small3.2:24b, against Claude-derived reference scores. Results reveal a trade-off: deepseek-r1 leads exact match (57.1%) due to perfect performance on composite indicators (100% exact); qwen3.5 dominates reliability with 100% within-±1 accuracy and zero false refusals; mistral-small3.2 performs poorly with four out of seven outputs as false refusals. We recommend qwen3.5:35b as a reliable AI draft scorer for assisting human assessors in higher-education accreditation.

Keywords: *automated assessment; large language models; retrieval-augmented generation; higher education accreditation*

ABSTRAK (DALAM BAHASA INDONESIA)

Audit Mutu Internal (AMI) pendidikan tinggi di Indonesia memerlukan penilaian manual terhadap puluhan indikator berdasarkan rubrik yang kompleks dengan dua sumber bukti heterogen: Laporan Evaluasi Diri (LED) yang kualitatif dan Laporan Kinerja Program Studi (LKPS) yang kuantitatif. Penelitian ini menguji apakah agen *Large Language Model* (LLM) *open-weight* dapat mengotomatisasi penilaian lintas-modal pada tujuh indikator inti proses pembelajaran dan kurikulum, serta bagaimana paradigma agen — *native function calling* dibanding *dispatch* JSON berbasis *prompt* — memengaruhi performa. Kami mengimplementasikan agen *Retrieval-Augmented Generation* (RAG) yang melakukan *cross-referencing* antara *chunk* LED ter-indeks vektor dengan tabel LKPS terstruktur melalui empat *tool* khusus, kemudian melakukan *benchmark* tiga model *open-weight* berukuran sebanding

(24–35 miliar parameter): qwen3.5:35b, deepseek-r1:32b, dan mistral-small3.2:24b, terhadap skor referensi yang dihasilkan Claude. Hasil mengungkap sebuah *trade-off*: deepseek-r1 unggul *exact match* (57,1%) karena performa sempurna pada indikator komposit (100% *exact*); qwen3.5 mendominasi reliabilitas dengan akurasi *within*-±1 sebesar 100% dan tanpa *false refusal*; mistral-small3.2 berperforma buruk dengan empat dari tujuh keluaran sebagai *false refusal*. Kami merekomendasikan qwen3.5:35b sebagai *AI draft scorer* yang andal bagi asesor manusia dalam akreditasi pendidikan tinggi.

Kata kunci: *penilaian otomatis; large language models; retrieval-augmented generation; akreditasi pendidikan tinggi*

INTRODUCTION

Akreditasi program studi merupakan instrumen utama penjaminan mutu pendidikan tinggi di Indonesia. Pada bidang teknik, akreditasi dilakukan melalui Lembaga Akreditasi Mandiri Teknik (LAM Teknik) dengan rubrik 60+ indikator yang dinilai pada skala 0–4 oleh asesor tersertifikasi. Penilaian dilakukan dengan *cross-referencing* manual antara dua dokumen yang sangat berbeda: Laporan Evaluasi Diri (LED) berupa PDF naratif sepanjang 150–200 halaman yang berisi narasi kualitatif, serta Laporan Kinerja Program Studi (LKPS) berupa berkas Excel dengan 50 *sheet* yang memuat data kuantitatif. Proses ini membutuhkan waktu beberapa hari per program studi, melibatkan biaya asesor yang tinggi, dan rentan terhadap inkonsistensi antar penilai.

Pemanfaatan teknologi *Large Language Model* (LLM) untuk membantu penilaian akademik telah menjadi area riset yang aktif berkembang. Yao, Zhao, Yu, Du, Shafran, Narasimhan, & Cao (2023) memperkenalkan paradigma ReAct yang memungkinkan LLM berinteraksi dengan *tool* secara iteratif, sementara Lewis et al. (2020) memperkenalkan *Retrieval-Augmented Generation* (RAG) yang memungkinkan penalaran LLM tetap *grounded* pada bukti dokumen. Zheng et al. (2023) menunjukkan bahwa LLM dapat berperan sebagai *judge* untuk evaluasi otomatis dengan korelasi kuat terhadap penilai manusia. Es, James, Espinosa-Anke, & Schockaert (2024) memperluas pendekatan ini melalui *framework* RAGAS yang spesifik untuk sistem RAG.

Beberapa studi terkini telah memanfaatkan LLM dalam konteks pendidikan tinggi, mulai dari penilaian esai (Dutt & Ismail, 2019), prediksi kinerja mahasiswa, hingga *chatbot* layanan akademik. Namun, sejauh pengetahuan kami, belum ada penelitian yang fokus pada otomasi proses akreditasi pendidikan tinggi Indonesia berbasis LLM, terutama yang menggabungkan dua dokumen heterogen seperti LED dan LKPS. Studi yang ada juga umumnya memanfaatkan LLM komersial (GPT, Claude, Gemini) yang berisiko tinggi terhadap kerahasiaan data institusional, padahal dokumen akreditasi sering bersifat sensitif dan harus tetap berada dalam *perimeter* institusi.

Riset terbaru pada model *open-weight* berukuran 20–35 miliar parameter — seperti Qwen, DeepSeek, dan Mistral — menunjukkan bahwa model dengan kapasitas moderat dapat menangani tugas berbasis *tool* dengan biaya komputasi yang dapat diakses lembaga pendidikan. Lebih lanjut, agen LLM dapat dibangun dengan dua paradigma *tool-dispatch*: *native function calling* untuk model dengan dukungan *tool* bawaan (Qwen, Mistral), dan

prompt-based JSON dispatch untuk model *reasoning* (DeepSeek-R1) yang menghasilkan blok `<think>...</think>` sehingga tidak dapat menggunakan *function calling* native pada infrastruktur Ollama (Yu, Wang, & Liu, 2024). Pertanyaan yang belum terjawab adalah model dan paradigma mana yang paling sesuai untuk penilaian akreditasi yang didominasi indikator kualitatif dan komposit.

Penelitian ini bertujuan: (1) merancang agen RAG lintas-modal *open-source* yang memadukan *vector retrieval* atas LED dengan *table lookup* atas LKPS melalui empat *tool* khusus; (2) melakukan *benchmark* tiga model *open-weight* (qwen3.5:35b, deepseek-r1:32b, mistral-small3.2:24b) pada tujuh indikator inti proses pembelajaran dan kurikulum dari rubrik LAM Teknik; serta (3) menganalisis *trade-off exact-match versus reliability* antar model dan mengidentifikasi *failure mode* yang muncul pada konteks penilaian akreditasi pendidikan Indonesia. Hasil penelitian diharapkan memberikan rekomendasi konkret bagi institusi pendidikan tinggi yang ingin memanfaatkan agen LLM sebagai *AI draft scorer* yang mempercepat proses audit mutu internal tanpa menggantikan peran asesor manusia sebagai *final decision-maker*.

METHODS

Pendekatan dan ruang lingkup. Penelitian ini menggunakan pendekatan *quantitative experimental* dengan metode *benchmarking*. Ruang lingkup terbatas pada tujuh indikator inti proses pembelajaran dan kurikulum dari rubrik LAM Teknik, yaitu: Indikator 14 (Kesesuaian dan tinjauan CPL), 15 (Rencana Proses Pembelajaran/RPS), 16 (Proses Pembelajaran), 17 (Integrasi Penelitian dan PkM dalam pembelajaran), 20 (Capstone Design), 22 (Penelitian), dan 24 (Pengabdian kepada Masyarakat). Subset ini terdiri dari tiga indikator komposit (14, 15, 16) dan empat indikator kualitatif (17, 20, 22, 24), menyediakan *coverage* seimbang antara *judgment* teks dan kombinasi *judgment* + formula bobot.

Definisi operasional variabel. Variabel utama adalah skor model LLM (skala 0–4) untuk setiap indikator, dibandingkan terhadap skor referensi yang dihasilkan Claude (Anthropic) sebagai *LLM-as-annotator*. Variabel pendukung meliputi *justification* (teks penjelasan skor), *confidence* (rentang 0,0–1,0 yang dihasilkan model), *runtime* (detik per indikator), serta *tipe indikator* (kualitatif, komposit).

Lokasi dan sampel. Penelitian dilakukan pada satu program studi sarjana terapan jarak jauh bidang teknik di sebuah politeknik negeri Indonesia, yang dianonimkan sebagai *Program A*. Dokumen LED dan LKPS yang digunakan adalah dokumen versi *post-audit* dari periode 2024. Penggunaan satu program disengaja sebagai studi awal yang *tractable*, sementara generalisasi ke program lain merupakan *future work* yang diakui sebagai keterbatasan.

Material dan tool utama. Sistem dibangun dengan komponen utama: (1) *Embedding model* `paraphrase-multilingual-MiniLM-L12-v2` (384-dimensi) untuk indeksasi LED; (2) ChromaDB sebagai *vector database* dengan HNSW *cosine similarity*; (3) LangGraph sebagai *framework agent state machine*; (4) Ollama sebagai *inference backend* model lokal pada server GPU 24 GB VRAM yang diakses melalui *Cloudflare-tunneled HTTPS endpoint*; serta (5) Claude (Anthropic) sebagai *reference annotator* awal.

Empat tool yang dipaparkan ke agen adalah: (a) `get_indicator_rubric(indicator_no)` — mengembalikan kriteria skor, formula, dan referensi tabel LKPS; (b) `search_led_evidence(query, n_results)` — *vector search* atas *chunk* LED; (c) `get_lkps_table(table_reference)` — mengembalikan tabel LKPS sebagai *markdown*; (d) `compute_formula_score(formula_expression, variables)` — eval Python tersandbox untuk indikator berbasis formula.

Dua paradigma agen diterapkan secara otomatis berdasarkan pola nama model. Paradigma *native* (untuk qwen3.5:35b dan mistral-small3.2:24b) menggunakan `tool_calls` terstruktur yang langsung dieksekusi `ToolNode` LangGraph. Paradigma *prompt-based* (untuk deepseek-r1:32b) meminta model menghasilkan JSON satu baris dengan format `{"action": ..., "args": ...}` untuk panggilan *tool* atau `{"action": "final", "score": ..., "justification": ..., "confidence": ...}` untuk jawaban final, dengan blok `<think>...</think>` di-*strip* terlebih dahulu sebelum ekstraksi JSON.

Teknik pengumpulan data. Setiap indikator dievaluasi sekali per model dengan parameter *sampling* yang sama (temperatur 0,1) untuk menghasilkan total 21 invokasi agen (tiga model × tujuh indikator). Hasil di-*stream* langsung ke berkas CSV untuk menjaga *durability* data terhadap kegagalan koneksi. Skor referensi Claude dihasilkan secara terpisah menggunakan rubrik lengkap, top-2 *chunk* LED dari *vector search*, dan ekstrak tabel LKPS yang relevan.

Teknik analisis data. Analisis kuantitatif menggunakan enam metrik: (1) Mean Absolute Error (MAE); (2) Root Mean Squared Error (RMSE); (3) *exact match* (rasio skor identik dengan referensi); (4) akurasi *within*-±1 (rasio kasus dengan |selisih| ≤ 1, ambang batas yang umum diterima sebagai kesepakatan antar asesor); (5) korelasi linier Pearson r; (6) *score-zero rate* sebagai proksi *failure mode false refusal*. Analisis dilakukan terpisah untuk indikator kualitatif dan komposit untuk mengungkap profil performa per tipe.

RESULTS AND DISCUSSION

Performa Agregat

Tabel 1 merangkum performa agregat ketiga model pada tujuh indikator proses pembelajaran dan kurikulum. Dua temuan utama menonjol. *Pertama*, deepseek-r1:32b memimpin metrik *exact match* sebesar 57,1% dengan MAE yang kompetitif (0,71). *Kedua*, qwen3.5:35b mendominasi reliabilitas dengan akurasi *within*-±1 sempurna 100% dan MAE terbaik (0,57), meskipun *exact match*-nya lebih rendah (42,9%).

Tabel 1. Performa Agregat Tiga Model pada Tujuh Indikator

Model	MAE ↓	RMSE ↓	*Exact* ↑	*Within*-±1 ↑	Pearson r	Conf.	RT/ind
qwen3.5:35b	**0,57**	**0,76**	42,9%	**100,0%**	0,35	0,78	30,2 d
deepseek-r1:32b	0,71	1,25	**57,1%**	85,7%	**0,41**	0,74	68,2 d
mistral-small3.2:24b	1,81	2,15	14,3%	42,9%	0,34	0,88	14,1 d

Mistral-small3.2:24b berperforma jauh di bawah dua model lainnya dengan MAE 1,81 dan akurasi *within*-±1 hanya 42,9%. Menariknya, model ini justru memiliki rerata *confidence* tertinggi (0,88) — sebuah pola *overconfidence* yang juga muncul pada perilaku *false refusal*-

nya. Pola serupa pernah dilaporkan oleh Yu et al. (2024) pada model *chat* berukuran menengah yang *instruction-tuning*-nya menekankan *helpfulness* tanpa *epistemic calibration* yang memadai.

Per-Type Breakdown: Trade-off Komposit vs Kualitatif

Tabel 2 mengungkap **temuan utama** penelitian ini: ketiga model menunjukkan profil performa yang sangat berbeda pada indikator komposit dibandingkan kualitatif murni.

Tabel 2. *Per-Type Breakdown* Performa per Tipe Indikator

Model	Tipe	n	MAE ↓	*Exact* ↑	±1 ↑	Skor=0
qwen3.5:35b	Kualitatif	4	0,75	25,0%	**100,0%**	0
qwen3.5:35b	Komposit	3	0,33	66,7%	**100,0%**	0
deepseek-r1:32b	Kualitatif	4	1,25	25,0%	75,0%	1
deepseek-r1:32b	Komposit	3	**0,00**	**100,0%**	**100,0%**	0
mistral-small3.2:24b	Kualitatif	4	2,45	0,0%	25,0%	**3**
mistral-small3.2:24b	Komposit	3	1,22	33,3%	66,7%	1

Deepseek-r1:32b mencapai performa sempurna pada indikator komposit: 100% *exact match* di seluruh tiga indikator (14, 15, 16) dengan MAE 0,00. Pada indikator kualitatif murni, performanya turun signifikan ke MAE 1,25 dengan satu kasus *false refusal* (Indikator 20: Capstone Design diberi skor 0 padahal LED jelas menyebutkan implementasi).

Qwen3.5:35b menunjukkan profil paling konsisten: 100% akurasi *within*-±1 di kedua tipe, tanpa satupun *false refusal*. Walaupun *exact match*-nya tidak setinggi deepseek-r1 di komposit (qwen 66,7% vs deepseek 100,0%), qwen tidak pernah salah lebih dari satu poin dari referensi.

Mistral-small3.2:24b gagal pada kategori kualitatif: 0% *exact* dan 3 dari 4 indikator menjadi *false refusal* (skor 0 dengan justifikasi "Tidak ada informasi yang diberikan" meski *chunk* LED ter-*retrieve*).

Studi Kasus per Indikator

Tabel 3 menampilkan skor model versus referensi untuk seluruh tujuh indikator, dengan *marker* (✓ = *exact*, ~ = *within*-±1, ✗ = selisih

1).

Tabel 3. Skor per Indikator dan *Marker Disagreement*

No	Tipe	Ref	deepseek-r1	mistral-small	qwen3.5
14	Komposit	3,0	3,0 ✓	3,0 ✓	3,0 ✓
15	Komposit	3,0	3,0 ✓	2,3 ~	3,0 ✓
16	Komposit	3,0	3,0 ✓	0,0 ✗	4,0 ~
17	Kualitatif	2,0	1,0 ~	0,0 ✗	3,0 ~
20	Kualitatif	3,0	0,0 ✗	0,0 ✗	3,0 ✓
22	Kualitatif	3,0	2,0 ~	0,0 ✗	4,0 ~
24	Kualitatif	3,0	3,0 ✓	4,0 ~	4,0 ~

Indikator 14 (Kesesuaian CPL): Ketiga model sepakat dengan referensi (3,0). Ini menunjukkan bahwa indikator dengan rubrik dan bukti yang sangat eksplisit dapat dinilai konsisten oleh berbagai keluarga model. Indikator 20 (Capstone Design) merupakan kasus paling menarik: **baik deepseek-r1 maupun mistral-small3.2 mengalami *false refusal*** (skor 0), padahal LED p. 77 secara eksplisit menyebutkan pelaksanaan Capstone melalui Pedoman Capstone Project. Hanya qwen3.5 yang memberikan skor benar (3,0).

Failure Mode: False Refusal sebagai Kegagalan Dominan

Pada subset tujuh indikator ini, *failure mode* yang paling dominan adalah ***false refusal*** — model memberikan skor 0 dengan justifikasi "Tidak ada bukti" meski bukti ada di *chunk* LED yang ter-*retrieve*. Tabel 4 merangkum tingkat *false refusal* per model.

Tabel 4. *False Refusal* per Model

Model	Total skor=0	Indikator yang difalse-refuse
qwen3.5:35b	**0**	(tidak ada)
deepseek-r1:32b	1	20 (Capstone)
mistral-small3.2:24b	4	16, 17, 20, 22

Qwen3.5:35b menunjukkan reliabilitas sempurna — tidak pernah menolak menilai. Ini konsisten dengan pelatihan Qwen pada tugas *agentic* yang menekankan *decisiveness*. Deepseek-r1:32b mengalami *false refusal* hanya pada Indikator 20. Inspeksi blok `<think>...</think>` menunjukkan model membaca *chunk* LED yang relevan tetapi menyimpulkan "*evidence is too generic*" — sebuah *over-cautious refusal*. Mistral-small3.2:24b menunjukkan *false refusal* parah pada 4 dari 7 indikator. Pola justifikasi yang berulang menyiratkan bahwa *instruction-tuning* model ini menekankan *"explanatory caution"* alih-alih *"agentic decisiveness"* — sebuah *trade-off* yang sebelumnya diidentifikasi pada model *chat* berukuran menengah (Yu et al., 2024).

Trade-off antara Exact Match dan Reliabilitas

Pemilihan model untuk penilaian akreditasi otomatis bukan keputusan satu dimensi. Deepseek-r1:32b mencapai *exact match* tertinggi (57,1%) tetapi dengan satu kasus *off-error* besar (Indikator 20: skor 0 vs ref 3). Sebaliknya qwen3.5:35b "hanya" mencapai 42,9% *exact match*, namun **tidak pernah** salah lebih dari satu poin dari referensi. Untuk *deployment* sebagai *draft*

scorer yang akan diverifikasi asesor manusia, reliabilitas qwen lebih bernilai daripada *exact match* deepseek: asesor hanya perlu mengoreksi ±1 daripada me-*redo* penilaian dari nol.

Hipotesis kami untuk superioritas deepseek-r1 pada komposit: struktur komposit secara natural cocok dengan *chain-of-thought* model *reasoning* — model dapat secara terpisah menilai sub-skor I, menilai sub-skor II, kemudian menerapkan formula sebagai langkah penalaran terakhir. Tahap-tahap ini eksplisit di blok `<think>` yang dapat di-inspeksi, dan jarang gagal. Sebaliknya, indikator kualitatif murni membutuhkan pemberian skor *one-shot* yang bergantung pada *holistic judgment* — area di mana model *reasoning* kurang unggul dibandingkan model dengan *tool-tuning* khusus seperti Qwen.

Implikasi untuk Praktik Akreditasi

Hasil penelitian memberikan rekomendasi konkret bagi institusi pendidikan tinggi. Untuk *draft scorer* yang andal, qwen3.5:35b direkomendasikan karena reliabilitasnya konsisten — 100% *within*-±1 berarti asesor manusia hanya perlu *fine-tuning* satu poin. Deepseek-r1:32b dapat menjadi alternatif untuk *batch* indikator yang didominasi struktur komposit, dengan kewaspadaan terhadap kasus *false refusal* yang sesekali muncul. Mistral-small3.2:24b sebaiknya dihindari untuk indikator dominan kualitatif karena tingkat *false refusal* 75% pada kategori ini akan membutuhkan koreksi manual yang ekstensif.

Penting digarisbawahi bahwa pendekatan ini ditujukan sebagai *human-in-the-loop assistive tool*, bukan pengganti asesor tersertifikasi. Penilaian final tetap berada pada asesor manusia, dengan agen LLM berperan sebagai akselerator yang mempersiapkan *draft* skor dan justifikasi yang dapat diverifikasi secara cepat.

CONCLUSION

Penelitian ini menyajikan *benchmark* fokus tiga LLM *open-weight* berukuran 24–35 B parameter pada tujuh indikator proses pembelajaran dan kurikulum dari rubrik LAM Teknik. Temuan utama: deepseek-r1:32b mencapai *exact match* tertinggi (57,1%; MAE 0,71) berkat performa sempurna pada indikator komposit (100% *exact*); qwen3.5:35b unggul dalam reliabilitas dengan akurasi *within*-±1 sempurna 100% (MAE 0,57) tanpa *false refusal*; mistral-small3.2:24b berperforma buruk (MAE 1,81; *exact* 14,3%) dengan empat dari tujuh keluaran sebagai *false refusal*. Temuan utama paper ini adalah *trade-off* antara *exact match* (deepseek-r1) dan reliabilitas (qwen3.5), serta dominansi *failure mode false refusal* pada model *chat* berukuran menengah.

Untuk *deployment* praktis sebagai *AI draft scorer* yang akan diverifikasi asesor manusia dalam audit mutu internal pendidikan tinggi, penelitian ini merekomendasikan qwen3.5:35b karena reliabilitasnya konsisten dengan akurasi *within*-±1 mencapai 100%. Model ini tidak pernah memberikan kesalahan besar yang berisiko menggagalkan penilaian. Untuk batch indikator yang didominasi struktur komposit, deepseek-r1:32b dapat menjadi alternatif yang menjanjikan dengan kewaspadaan terhadap *false refusal*.

Kontribusi penelitian ini bagi pengembangan ilmu pengetahuan adalah *benchmark* pertama LLM *open-weight* pada konteks akreditasi pendidikan tinggi Indonesia, identifikasi *trade-off* model untuk penilaian rubrik bertingkat, serta rekomendasi praktis untuk deployment AI di institusi pendidikan tinggi. Saran untuk penelitian selanjutnya meliputi: (1) ekstensi ke seluruh

60 indikator, terutama indikator kuantitatif murni; (2) validasi oleh ahli akreditasi manusia tersertifikasi; (3) pengujian pada beberapa program studi untuk memvalidasi generalisasi; serta (4) eksplorasi paradigma agen hybrid yang dapat menggabungkan keunggulan komposit deepseek-r1 dan reliabilitas qwen3.5.

DAFTAR PUSTAKA

Dutt, A., & Ismail, M. A. (2019). Can We Predict Student Learning Performance from LMS Data? A Classification Approach. *3rd International Conference on Current Issues in Education (ICCIE 2018), 326*(ICCIE 2018), 24–29. https://doi.org/10.2991/iccie-18.2019.5

Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2024). RAGAS: Automated Evaluation of Retrieval Augmented Generation. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 150–158.

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2024). Retrieval-Augmented Generation for Large Language Models: A Survey. *arXiv preprint arXiv: 2312.10997*.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474.

Mokshein, S. E. (2019). Education for Sustainable Development (ESD) in Malaysia: Policy, Program and Evaluation. *3rd International Conference on Current Issues in Education (ICCIE 2018), 326*(ICCIE 2018), 6–12. https://doi.org/10.2991/iccie-18.2019.2

Reimers, N., & Gurevych, I. (2020). Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 4512–4525. https://doi.org/10.18653/v1/2020.emnlp-main.365

Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N., & Scialom, T. (2023). Toolformer: Language Models Can Teach Themselves to Use Tools. *Advances in Neural Information Processing Systems, 36*.

Supriyanta, E. Y., Mustadi, A., Wangid, M. N., & Suhardi. (2019). Sociocultural-Based Reflective Picture Storybook: Urgency in Social Skill Development. *3rd International Conference on Current Issues in Education (ICCIE 2018), 326*(ICCIE 2018), 162–166. https://doi.org/10.2991/iccie-18.2019.29

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, 843–857.

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. *International Conference on Learning Representations (ICLR 2023)*.

Yu, P., Wang, B., & Liu, T. (2024). Evaluating Tool-Use Capabilities of Large Language Models in Multi-Step Reasoning Tasks. *arXiv preprint arXiv:2407.18901*.

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems, 36*, 46595–46623.